

# Probabilidad y Estadística

## Clase 3

# Esperanza condicional

# Función de regresión

**Def:** Sean  $X, Y$  dos v.a. **discretas**, se llama **función de regresión** a

$$\varphi(x) = \mathbb{E}[Y|X = x] = \sum_{y \in R_Y} y p_{Y|X=x}(y), \quad \forall x \in R_X$$

**Def:** Sean  $X, Y$  dos v.a. **continuas**, se llama **función de regresión** a

$$\varphi(x) = \mathbb{E}[Y|X = x] = \int_{y \in R_Y} y f_{Y|X=x}(y), \quad \forall x \in R_X$$

Observar que es función de  $x$

# Ejercicio 1

Siguiendo con los ejercicios de la clase pasada calcular la función de regresión de  $X|Y=y$  o  $Y|X=x$  según corresponda

1. La probabilidad de acertar a un blanco es  $\frac{1}{5}$ . Se realizan 10 tiros independientes y se cuenta la cantidad de aciertos. Sean  $X$  la cantidad de aciertos en los 10 tiros, e  $Y$  la cantidad de aciertos en el primer tiro. Hallar la distribución de  $X|Y=y$  y  $Y|X=x$ .
2. Sean  $X, Y$  dos v.a. conjuntamente uniformes en el triángulo de vértices  $(0,0)$ ,  $(2,2)$ ,  $(0,2)$ . Hallar la función de densidad de  $Y|X=x$ .

Sean  $X, Y$  dos v.a. con función de densidad conjunta

$$f_{X,Y}(x,y) = \frac{e^{-x/2y}}{4y} \mathbf{1}\{0 < x, 1 < y < 3\}$$

Hallar la función de densidad de  $X|Y=y$

# Esperanza condicional

**Def:** La variable aleatoria **esperanza condicional de  $Y$  dada  $X$**  se define como

$$\mathbb{E}[Y|X] = \varphi(X).$$

Además  $\varphi(X)$  satisface que  $\mathbb{E}[(Y - \varphi(X)) t(X)] = 0$  para toda función medible  $t : R_X \rightarrow \mathbb{R}$ , tal que  $\mathbb{E}[t(X)] < \infty$ .

¿A qué nos recuerda esto?

$\mathbb{E}[Y|X]$  es el **mejor predictor** de  $Y$  basado en  $X$  (i.e. es la **proyección ortogonal** de  $Y$  en el espacio de funciones de  $X$ )

# Propiedades

1.  $\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]]$
2.  $\mathbb{E}[r(X)s(Y)|X] = r(X)\mathbb{E}[s(Y)|X]$ , para  $r, s$  tal que  $r(X)s(X)$ ,  $r(X)$  y  $s(Y)$  tienen esperanza finita
3.  $\mathbb{E}[aY_1 + bY_2|X] = a\mathbb{E}[Y_1|X] + b\mathbb{E}[Y_2|X]$
4.  $\mathbb{E}[Y|X] = \mathbb{E}[Y]$  si  $X$  y  $Y$  son independientes

# Ejercicio 2

1. Siguiendo con los ejemplos del Ej. 1 calcular la esperanza condicional de  $X|Y$  o  $Y|X$  según corresponda
2. Para el último ejemplo, calcular  $E[X]$

# Varianza condicional

**Def:** Dada  $\tau(x) = \text{var}(Y|X = x)$ , se define la **varianza condicional** como

$$\mathbb{V}(Y|X) = \tau(X) = \mathbb{E}[Y^2|X] - \mathbb{E}[Y|X]^2$$

**Propiedad:** (Pitágoras)

$$\text{var}(Y) = \mathbb{E}[\mathbb{V}(Y|X)] + \text{var}(\mathbb{E}[Y|X])$$



# Ejercicio 3

1. Siguiendo con los ejemplos del Ej. 1 calcular la varianza condicional de  $X|Y$  o  $Y|X$  según corresponda
2. Para el último ejemplo, calcular  $\text{var}[X]$

# Algunos comportamientos límite

LGN + TCL

# Ley (débil) de los grandes números

Sea  $\underline{X} = (X_1, \dots, X_n)$  una muestra aleatoria, con  $X_i$  i.i.d con media  $\mu$  y varianza  $\sigma^2$ . Para  $\epsilon > 0$  se tiene que

$$P\left\{\left|\frac{\sum_{t=1}^N X_t}{N} - \mu\right| > \epsilon\right\} \rightarrow 0 \text{ cuando } N \rightarrow \infty$$

Es decir, a medida que crece la cantidad de muestras, el promedio tiende a la media real de la distribución.

# Ejercicio 1

Simular la LGN usando Python para:

1.  $X_1, \dots, X_n \stackrel{i.i.d}{\sim} \mathcal{N}(5, 9)$

2.  $X_1, \dots, X_n \stackrel{i.i.d}{\sim} \mathcal{U}(2, 4)$

3.  $X_1, \dots, X_n \stackrel{i.i.d}{\sim} \mathcal{Bin}(10, 1/4)$

# Teorema central del límite

Sea  $\underline{X} = (X_1, \dots, X_n)$  una muestra aleatoria, con  $X_i$  i.i.d con media  $\mu$  y varianza  $\sigma^2$ . Luego,

$$\mathbb{P} \left( \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq z \right) \xrightarrow{n \rightarrow \infty} \Phi(z), \quad \Phi(z) = \mathbb{P}(Z \leq z), Z \sim \mathcal{N}(0, 1)$$

En general decimos que para  $n$  finitos diremos que

$$\mathbb{P} \left( \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq z \right) \approx \Phi(z),$$

$$\mathbb{P} \left( \sqrt{n} \frac{\bar{X}_i - \mu}{\sigma} \leq z \right) \approx \Phi(z),$$

# Ejercicio 2

Mostrar Notebook

# Estadística

# ¿Qué es la estadística?

Ahora lo que tenemos son observaciones (realizaciones) de las variables aleatorias.

El objetivo es poder hacer algún tipo de inferencia a partir de los valores observados.



# Muestra aleatoria

Supongamos que tenemos un experimento aleatorio relacionado con una v.a.  $X$ . La v.a.  $X$  representa un **observable** del experimento aleatorio.

Los valores de  $X$  son la **población** de estudio, y el objetivo es saber como se comporta esa población.

Una **muestra aleatoria** de tamaño  $n$ , es una sucesión de  $n$  v.a **independientes**  $\underline{X}_n = (X_1, \dots, X_n)$ , tal que  $X_i \sim X$

# Estimador

**Def:** Un **estimador** para una cierta magnitud  $\theta$  (desconocida) de la distribución de cierta población es una función  $\delta(\underline{X})$  de la muestra aleatoria, que devuelve un valor aproximado de  $\theta$ .

# Error cuadrático medio

**Def:** El error cuadrático medio (ECM) como  $\mathbb{E}[(\delta(\underline{X}_n) - \theta)^2]$

**Def:** Un estimador  $\delta^*(\underline{X})$  es **óptimo** si

$ECM(\delta^*(\underline{X})) \leq ECM(\delta(\underline{X}))$  para todo  $\delta(\underline{X})$ .

# Ejercicio 3

Se desea estimar la media de una variable con distribución  $N(5,9)$  a partir del promedio de  $n$  realizaciones. Hallar el ECM para distintos valores de  $n$ .

# Estimadores de mínimos cuadrados

# Estimador de mínimos cuadrados

Es común querer estimar el valor de una v.a.  $X$  a partir de una medición  $Y$ . Ejemplo:  $Y$  es una versión ruidosa de  $X$ .

Buscamos un estimador  $\hat{X}$  de  $X$  tal que tenga mínimo error cuadrático medio

$$ECM = \mathbb{E}[(X - \hat{X})^2]$$

Observar que se corresponde con la distancia asociada al p.i. canónico para v.a.

# Estimador de mínimos cuadrados

En otras palabras, queremos  $\hat{X} = g^*(Y)$  tal que

$$\mathbb{E}[(X - \hat{X})^2] \leq \mathbb{E}[(X - g(Y))^2] \quad \forall g(Y) \text{ (medible).}$$

¿Quién era  $\hat{X}$ ?  $\hat{X} = \mathbb{E}[X|Y]$

Idea de demostración: [Ejercicio]

1. Probar que el mejor estimador constante es  $\mathbb{E}[X]$
2. Probar que el mejor estimador condicional es  $\mathbb{E}[X|Y = y]$ .
3. Dejar que  $Y$  tome todos los valores posibles (i.e. reemplazo  $y$  por  $Y$ ), recupero la esperanza condicional.

# Mínimos cuadrados: caso lineal

A veces obtener  $\mathbb{E}[X|Y]$  puede ser muy complicado, entonces nos restringimos a los estimadores lineales.

Buscamos  $a, b$  tq  $\mathbb{E}[(X - (aY + b))^2]$  sea mínima.

Resulta que  $a = \frac{\text{cov}(X,Y)}{\text{var}(Y)}$  y  $b = \frac{\text{cov}(X,Y)}{\text{var}(Y)}\mathbb{E}[Y] + \mathbb{E}[X]$



# Ejercicio 4

Sea  $X \sim U(0,1)$  e  $Y = X^2$ . Hallar la mejor aproximación lineal de  $Y$  basada en  $X$ . Comparar con la mejor estimación de  $Y$  basada en  $X$ .

# Regresión lineal

Tengo las observaciones  $(x_1, \dots, x_n)$  e  $(y_1, \dots, y_n)$ ,  
observaciones de dos v.a.  $X$  e  $Y$ , y queremos hallar la mejor  
relación lineal  $Y = aX + b$ .

Definiendo  $A = \begin{bmatrix} x_1 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix}$ , tenemos que

$[a, b]^T = (A^T A)^{-1} A^T y$  Nuevamente, la demostración la  
vimos en AM.